


“Accelerating Sparse Indexes Via Term Impact Decomposition”

Joel Mackenzie, Antonio Mallia, Alistair
Moffat et Matthias Petri


Nour BOUCHOUCHI
Nolwenn PIGEON



Deux techniques pour améliorer l'efficiency : list splitting et postings clipping




(a) List Splitting



(b) Postings Clipping



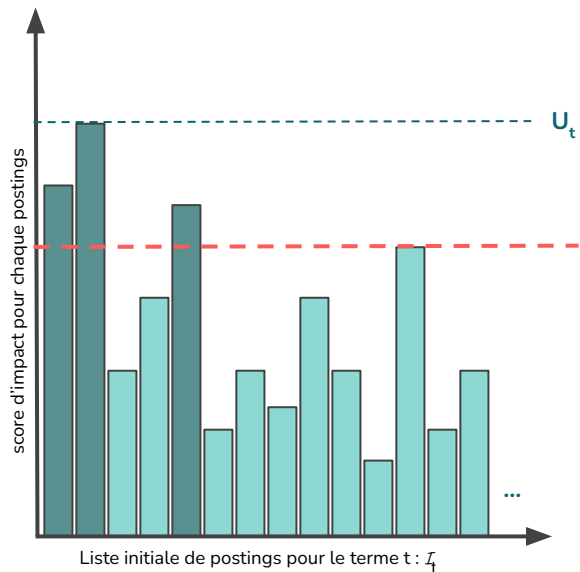
List splitting



List splitting

$$|\mathcal{I}_{\text{project}}| = 9\,142$$

$$|\mathcal{I}_{\text{project}}| = 10\,226$$




DeepImpact : 1,1 Go
BM25 : 416 M0



$$|\mathcal{L}(\text{project})| = 9\,000$$


$$|\mathcal{L}(\text{project})| = 10\,117$$



DeepImpact : 1,1 Go
BM25 : 420 M0


$$|\mathcal{H}(\text{project})| = 142$$

$$|\mathcal{H}(\text{project})| = 109$$





Postings clipping

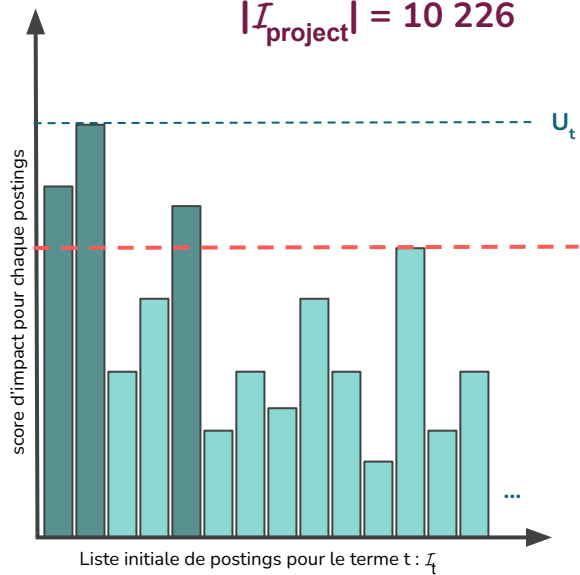


1/64e des postings ont un score d'impact supérieur

Postings clipping

$$|\mathcal{I}_{\text{project}}| = 9\,142$$


$$|\mathcal{I}_{\text{project}}| = 10\,226$$



DeepImpact : 1,1 Go
BM25 : 420 M0

$$|\mathcal{L}(\text{projet})| = 9\,142$$


$$|\mathcal{L}(\text{projet})| = 10\,226$$



DeepImpact : 1,2 Go
BM25 : 424 M0

$$|\mathcal{H}(\text{projet})| = 142$$

$$|\mathcal{H}(\text{projet})| = 109$$



Algorithme Wand et MaxScore

Smart Bounds : Prise en compte de $UL(t)$ et $UH(t)$.
Mise à jour de la borne supérieure devient : $UH(t) - UL(t)$.

Algorithm 1 WAND processing.

```

function WAND( $q, \mathcal{I}, k$ )
  for  $t \leftarrow 0$  to  $|q| - 1$  do
     $U[t] \leftarrow \max_d \{w_d \mid (d, w_d) \in \mathcal{I}_t\}$ 
     $(c_t, w_t) \leftarrow \text{first\_posting}(\mathcal{I}_t)$ 
5: end for
     $\theta \leftarrow -\infty$  // current threshold
     $Ans \leftarrow \{\}$  //  $k$ -set of  $(d, s_d)$  values
    while the set of candidates  $(c_t, w_t)$  is non-empty do
      permute the candidates so that  $c_0 \leq c_1 \leq \dots \leq c_{|q|-1}$ 
10:  $score\_limit \leftarrow 0$ 
       $pivot \leftarrow 0$ 
      while  $pivot < |q| - 1$  do
         $tmp\_s\_lim \leftarrow score\_limit + U[pivot]$ 
        if  $tmp\_s\_lim > \theta$  then
15: break, and continue from step 20
        end if
         $score\_limit \leftarrow tmp\_score\_lim$ 
         $pivot \leftarrow pivot + 1$ 
      end while
20: if  $c_0 = c_{pivot}$  then
       $s \leftarrow 0$  // score document  $c_{pivot}$ 
       $t \leftarrow 0$ 

```

```

      while  $t < |q|$  and  $c_t = c_{pivot}$  do
         $s \leftarrow s + w_t$  // add contribution to score
         $(c_t, w_t) \leftarrow \text{next\_posting}(\mathcal{I}_t)$ 
         $t \leftarrow t + 1$ 
      end while //  $s$  is the score of document  $c_{pivot}$ 
      if  $s > \theta$  then // and is a possible top- $k$  answer
         $Ans \leftarrow \text{insert}(Ans, (c_{pivot}, s))$ 
        if  $|Ans| > k$  then
           $Ans \leftarrow \text{delete\_smallest}(Ans)$ 
           $\theta \leftarrow \text{minimum}(Ans)$ 
        end if
      end if
35: else // can't score  $c_{pivot}$  (yet)
      for  $t \leftarrow 0$  to  $pivot - 1$  do
         $(c_t, w_t) \leftarrow \text{seek\_to\_document}(\mathcal{I}_t, c_{pivot})$ 
      end for // all pointers are now at  $c_{pivot}$  or greater
      end if
40: end while
      return  $Ans$ 
end function

```

Algorithm 1 Standard MaxScore. Input is a set of q postings lists \mathcal{I}_t , with $\mathcal{I}_{t,i} = \langle d, w \rangle$ the docnum and impact score of the i th posting for the t th term; and a vector $U_t = \max_i \{\mathcal{I}_{t,i}.w\}$, the maximum impact for the t th term.

```

1:  $active \leftarrow \{0 \dots q - 1\}$  // active terms
2:  $passive \leftarrow \{\}$  // passive terms
3:  $sum\_pass \leftarrow 0$  // sum of passive  $U_t$ 's
4:  $heap \leftarrow \{\}$  // heap of "best so far"
5:  $c[t] \leftarrow 0$  for  $0 \leq t < q$  // cursors
6:  $\theta \leftarrow -\infty$  // heap threshold
7: while active postings remain do
8: // select next document, match all cursors
9:  $d \leftarrow \min \{\mathcal{I}_{t,c[t]}.d \mid t \in active\}$ 
10: for  $t \in passive$  do
11:  $c[t] \leftarrow \text{SeekGEQ}(\mathcal{I}_t, d)$ 
12: // score document
13:  $score_d \leftarrow \sum \{\mathcal{I}_{t,c[t]}.w \mid \mathcal{I}_{t,c[t]}.d = d\}$ 
14: // advance cursors
15: for  $t \in active$  do
16: if  $\mathcal{I}_{t,c[t]}.d = d$  then
17:  $c[t] \leftarrow c[t] + 1$ 
18: // check against heap, update if needed
19: if  $score_d > \theta$  then
20:  $heap \leftarrow heap \cup \{\langle d, score_d \rangle\}$ 
21: if  $|heap| > k$  then
22: eject the least weight  $\langle d, score_d \rangle$ 
23: heap item and update  $\theta$ 
24: // try to expand passive set
25:  $y \leftarrow \text{argmax}_t \{|\mathcal{I}_t| \mid t \in active\}$ 
26: if  $sum\_pass + U_y < \theta$  then
27: // toggle term  $y$  from active to passive
28:  $active \leftarrow active - \{y\}$ 
29:  $passive \leftarrow passive \cup \{y\}$ 

```

Résultats

Nos
résultats :

Méthode	BM25		DeepImpact	
	K=10	K=1000	K=10	K=1000
MaxScore baseline	31.0	68.3	4 849.0	2 912.6
+ list splitting	21.1	58.2	58 879.6	4 010.4
+ posting clipping	28.2	71.4	2 603.6	3 534.1
Wand baseline	613.8	1 602.9	442.8	464.1
+ list splitting	451.6	1 842.1	121.0	161.7
+ posting clipping	357.1	1 452.3	468.0	692.4

Temps de traitement des requêtes en secondes par requête, deux modèles de recherche et deux approches d'élagage dynamique

Résultats
de l'article :

Méthode	BM25		DeepImpact	
	K=10	K=1000	K=10	K=1000
MaxScore baseline	1.7	5.5	8.1	18.8
+ list splitting	/	/	2.0	7.9
+ posting clipping	1.5	5.0	1.6	5.9
Wand baseline	2.3	7.4	14.9	34.0
+ list splitting	/	/	3.5	13.8
+ posting clipping	1.7	5.6	2.7	10.8

Temps de traitement des requêtes en millisecondes par requête, deux modèles de recherche et deux approches d'élagage dynamique

Annexes





Structure du code

- **create_index_deepimpact.py**
 - Permet de créer un index inversé à partir des index MSMARCOv1 avec Deepimpact et de l'enregistrer en mémoire sous format json. On indexe les 1 million premiers passages pour des raisons de problème de passage à l'échelle.
- **create_index_bm25.py**
 - Permet de créer un index inversé à partir des index MSMARCOv1 avec BM25 et de l'enregistrer en mémoire sous format json. On fait attention à conserver les mêmes passages que ceux qui ont été sélectionnés pour DeepImpact.
- **postings_clipping.py**
 - Permet de créer les index avec postings clipping pour DeepImpact et BM25 à partir des index inversés préalablement créés et de les enregistrer en mémoire sous format json.
- **list_splitting.py**
 - Permet de créer les index avec list splitting pour DeepImpact et BM25 à partir des index inversés préalablement créés et de les enregistrer en mémoire sous format json.
- **wand.py**
 - Permet de calculer le temps moyen des requêtes à l'aide de WAND, pour k=10 et k=1000, à partir des index inversés, avec postings clipping et avec list splitting.
- **maxscore.py**
 - Permet de calculer le temps moyen des requêtes à l'aide de MaxScore pour k=10 et k=1000, à partir des index inversés, avec postings clipping et avec list splitting.

```

1  import os
2  import json
3
4  def create_index(folder):
5      inverted_index = {}
6      # On n'indexe que les deux premiers fichiers (1 000 000 de passages)
7      for filename in os.listdir(folder):
8          if filename.endswith('.json') and int(filename[-7:-5])<2:
9              with open(os.path.join(folder, filename), 'r') as f:
10                 print("start indexing : ", filename)
11                 # On récupère les objets (passages) du fichier json
12                 for line in f:
13                     passage = json.loads(line)
14                     for word, score in passage['vector'].items():
15                         if word not in inverted_index:
16                             inverted_index[word] = {'postings': [], 'Ut': None}
17                         inverted_index[word]['postings'].append((passage['id'], score))
18             f.close()
19
20     # On ajoute le champ Ut pour chaque word
21     print("add Ut")
22     cpt = 0
23     nb_mots = len(inverted_index)
24     for word in inverted_index:
25         cpt+=1
26         if cpt%10000==0:
27             print("---"+str(cpt)+"/"+str(nb_mots))
28         postings = inverted_index[word]['postings']
29         ut = max(postings, key=lambda x: x[1])[1]
30         inverted_index[word]['Ut'] = ut
31
32
33     print("write index")
34     with open('indexes/inverted_index_deepimpact.json', 'w') as f:
35         json.dump(inverted_index, f)
36
37
38
39
40 if __name__ == '__main__':
41     create_index('collections/msmarco-passages-deepimpact')

```

create_index_deepimpact.py

```

1  import os
2  import json
3
4  def create_index(folder):
5      inverted_index = {}
6      # On parcourt tous les fichiers pour indexer les 1 000 000 de passages
7      # qu'on avait indexé avec deeimpact
8      nb_passages = 0
9      for filename in os.listdir(folder):
10         if filename.endswith('.json') :
11             with open(os.path.join(folder, filename), 'r') as f:
12                 print("start indexing : ", filename)
13                 # On récupère les objets (passages) du fichier json
14                 for line in f:
15                     passage = json.loads(line)
16                     # On ne récupère que les passages utilisés avec deeimpact
17                     if int(passage['id'])<1000000:
18                         nb_passages+=1
19                         if nb_passages%10000==0:
20                             print("----"+str(nb_passages)+"/1000000")
21                         for word, score in passage['vector'].items():
22                             if word not in inverted_index:
23                                 inverted_index[word] = {'postings': [], 'Ut': None}
24                             inverted_index[word]['postings'].append((int(passage['id']), int(score)))
25             f.close()
26
27     # On ajoute le champ Ut pour chaque word
28     print("add Ut")
29     cpt = 0
30     nb_mots = len(inverted_index)
31     for word in inverted_index:
32         cpt+=1
33         if cpt%10000==0:
34             print("----"+str(cpt)+"/"+str(nb_mots))
35         postings = inverted_index[word]['postings']
36         ut = max(postings, key=lambda x: x[1])[1]
37         inverted_index[word]['Ut'] = ut
38
39
40     print("write index")
41     with open('indexes/inverted_index_bm25.json', 'w') as f:
42         json.dump(inverted_index, f)
43
44
45
46
47 if __name__ == '__main__':
48     create_index('collections/msmarco-passages-bm25-b8')

```

create_index_bm25.py

```

1 postings_clipping.py > ...
2 import os
3 import sys
4 import json
5
6 def postings_clipping(folder, bm25=False):
7     new_index = {}
8
9     with open(folder, 'r') as f:
10         index = json.load(f)
11
12         # pour chaque terme dans l'index
13         cpt = 0
14         nb_mots = len(index)
15         for word, data in index.items():
16             cpt+=1
17             if cpt%1000==0:
18                 print("..."+str(cpt)+"-"+str(nb_mots))
19
20         postings = data['postings']
21
22         # Si le terme de l'index a plus de 256 postings (sinon on met tout dans L)
23         if len(postings) > 256:
24             # On ordonne les postings par ordre décroissants
25             postings = sorted(postings, key=lambda x: x[1], reverse=True)
26
27             # Nombre de postings dans H au max (de façon à ce que le plus bas score de H soit supérieur au meilleur de L)
28             len_H = len(postings) // 64
29             min_score_H = postings[len_H][1]
30             max_score_L = postings[len_H+1][1]
31             while not min_score_H > max_score_L and len_H>0:
32                 len_H -=1
33                 min_score_H = postings[len_H][1]
34                 max_score_L = postings[len_H+1][1]
35
36             if len_H==1:
37                 new_index[word] = {'L': {'postings': postings, 'Ut': data['Ut']}}
38             else:
39                 # On crée les listes L et H
40                 postings_L = []
41                 postings_H = []
42
43                 for doc, score in postings:
44                     if score > max_score_L:
45                         postings_H.append((doc, score-max_score_L))
46                     postings_L.append((doc, min(score, max_score_L)))
47
48                 # On calcule les valeurs Ut pour L et H
49                 Ut_L = postings_L[0][1]
50                 Ut_H = postings_H[0][1]
51
52                 # On ajoute les termes dans le nouvel index :
53                 new_index[word] = {'L': {'postings': postings_L, 'Ut': Ut_L}, 'H': {'postings': postings_H, 'Ut': Ut_H}}
54             else:
55                 new_index[word] = {'L': {'postings': postings, 'Ut': data['Ut']}}
56
57     f.close()
58
59     print("write index")
60     if bm25==True:
61         with open('indexes/index_postings_bm25.json', 'w') as f:
62             json.dump(new_index, f)
63     else:
64         with open('indexes/index_postings_deepimpact.json', 'w') as f:
65             json.dump(new_index, f)
66     print("done")
67
68 if __name__ == '__main__':
69     if len(sys.argv) > 1:
70         print("BM25")
71         file_path = 'indexes/inverted_index_bm25.json'
72         postings_clipping('indexes/inverted_index_bm25.json', True)
73     else:
74         print("DeepImpact")
75         file_path = 'indexes/inverted_index_deepimpact.json'
76         postings_clipping('indexes/inverted_index_deepimpact.json')
77

```

postings_clipping.py

```

1 list_splitting.py > list_splitting
2 import os
3 import sys
4 import json
5
6 def list_splitting(folder, bm25=False):
7     new_index = {}
8
9     with open(folder, 'r') as f:
10         index = json.load(f)
11
12         # pour chaque terme dans l'index
13         cpt = 0
14         nb_mots = len(index)
15         for word, data in index.items():
16             cpt+=1
17             if cpt%1000==0:
18                 print("..."+str(cpt)+"-"+str(nb_mots))
19
20         postings = data['postings']
21
22         # Si le terme de l'index a plus de 256 postings
23         if len(postings) > 256:
24             # On ordonne les postings par ordre décroissants
25             postings = sorted(postings, key=lambda x: x[1], reverse=True)
26
27             # Nombre de postings dans H au max (de façon à ce que le plus bas score de H soit supérieur au meilleur de L)
28             len_H = len(postings) // 64
29             min_score_H = postings[len_H][1]
30             max_score_L = postings[len_H+1][1]
31             while not min_score_H > max_score_L and len_H>0:
32                 len_H -=1
33                 min_score_H = postings[len_H][1]
34                 max_score_L = postings[len_H+1][1]
35
36             if len_H==1:
37                 new_index[word] = {'L': {'postings': postings, 'Ut': data['Ut']}}
38             else:
39                 # On crée les listes L et H
40                 postings_H = postings[:len_H+1]
41                 postings_L = postings[len_H+1:]
42
43                 # On calcule les valeurs Ut pour L et H
44                 Ut_L = postings_L[0][1]
45                 Ut_H = postings_H[0][1]
46
47                 # On ajoute les termes dans le nouvel index :
48                 new_index[word] = {'L': {'postings': postings_L, 'Ut': Ut_L}, 'H': {'postings': postings_H, 'Ut': Ut_H}}
49             else:
50                 new_index[word] = {'L': {'postings': postings, 'Ut': data['Ut']}}
51
52     f.close()
53
54     print("write index")
55     if bm25==True:
56         with open('indexes/index_splitting_bm25.json', 'w') as f:
57             json.dump(new_index, f)
58     else:
59         with open('indexes/index_splitting_deepimpact.json', 'w') as f:
60             json.dump(new_index, f)
61     print("done")
62
63 if __name__ == '__main__':
64     if len(sys.argv) > 1:
65         print("BM25")
66         file_path = 'indexes/inverted_index_bm25.json'
67         list_splitting(file_path, True)
68     else:
69         print("DeepImpact")
70         file_path = 'indexes/inverted_index_deepimpact.json'
71         list_splitting(file_path)
72

```

list_splitting.py

```

1 wand.py > ...
2 import heapq
3 import csv
4 import time
5 import json
6
7 def seek_to_document(postings_list, curseur, d):
8     """
9     Fait avancer l'itérateur du terme t jusqu'au premier numéro
10    de document supérieur ou égal à d
11    """
12    for c,posting in enumerate(postings_list[curseur]):
13        if posting[0] >= d:
14            return posting, c+curseur
15    return None, len(postings_list)
16
17 def candidates(cursors, postings_list):
18     for i in range(len(cursors)):
19         if cursors[i] < len(postings_list[i]):
20             return True
21     return False
22
23 def maj_candidats(cursors, postings_list):
24     candidats = []
25     for i in range(len(cursors)):
26         if cursors[i] < len(postings_list[i]):
27             candidats.append(postings_list[i][cursors[i]])
28     return candidats
29
30 def WAND(query, index, k, postings_clipping = False, list_splitting=False):
31     postings_list = []
32     liste_Ut = []
33     curseurs = []
34     candidats = [] #format (doc, score)
35     if list_splitting:
36         Ht_list_split = [] #pour list splitting (fait correspondre le H(t))
37     for term in query:
38         if term in index:
39             if postings_clipping or list_splitting:
40                 if index[term].get("H")!=None:
41                     postings_list.append(sorted(index[term]["H"]["postings"], key=lambda x: x[0], reverse=False))
42                     liste_Ut.append(index[term]["H"]["Ut"])
43                     curseurs.append(0)
44                     candidats.append(postings_list[-1][0])
45                 if list_splitting:
46                     Ht_list_split.append(0)
47                 if index[term].get("L")!=None:
48                     postings_list.append(sorted(index[term]["L"]["postings"], key=lambda x: x[0], reverse=False))
49                     liste_Ut.append(index[term]["L"]["Ut"])
50                     curseurs.append(0)
51                     candidats.append(postings_list[-1][0])
52                 if list_splitting:
53                     if index[term].get("H")!=None:
54                         Ht_list_split.append(liste_Ut[-2])
55                     else:
56                         Ht_list_split.append(0)
57             else:
58                 #On trie les documents par ordre croissants
59                 postings_list.append(sorted(index[term]["postings"], key=lambda x: x[0], reverse=False))
60                 liste_Ut.append(index[term]["Ut"])
61                 curseurs.append(0)
62                 candidats.append(postings_list[-1][0])
63
64

```

```

theta = float('-inf') # Seuil initial
Ans = [] # k-set of (d, s) values
# Tant qu'il y a des candidats
doc_pivot=1
while candidates(curseurs, postings_list):
    # Permutation des candidats pour avoir c0 <= c1 <= ... <= c|q|-1 (numéro de doc croissant parmi les candidats)
    candidats = maj_candidats(curseurs, postings_list)
    if list_splitting:
        candidats, curseurs, postings_list, liste_Ut, Ht_list_split = zip(*sorted(zip(candidats, curseurs, postings_list, liste_Ut, Ht_list_split), key=lambda x: x[0]))
    else:
        candidats, curseurs, postings_list, liste_Ut = zip(*sorted(zip(candidats, curseurs, postings_list, liste_Ut), key=lambda x: x[0]))
    curseurs = list(curseurs)
    postings_list = list(postings_list)
    liste_Ut = list(liste_Ut)
    if list_splitting:
        Ht_list_split = list(Ht_list_split)

    score_limit = 0
    pivot = 0
    # Recherche du pivot
    while pivot < len(liste_Ut) - 1:
        tmp_score_lim = score_limit + liste_Ut[pivot]

        if list_splitting:
            tmp_score_lim -= Ht_list_split[pivot]

        if tmp_score_lim > theta:
            break

    score_limit = tmp_score_lim
    pivot += 1
    doc_pivot = candidats[pivot][0]
    if candidats[0][0] == candidats[pivot][0]:
        s = 0 # Score du document pivot
        t = 0

        while t < len(liste_Ut) and candidats[t][0]==doc_pivot:
            s += candidats[t][1] # Contribution au score
            curseurs[t] += 1
            if curseurs[t]<len(postings_list[t])-1:
                candidats[t] = postings_list[t][curseurs[t]] # Posting suivant pour le terme t
            t+=1
        if s >= theta: # Réponse possible pour les meilleures k réponses
            heapq.heappush(Ans,(doc_pivot,s))

            if len(Ans) > k:
                Ans.remove(min(Ans, key=lambda x: x[1]))
                theta = Ans[0][1]

        else: # Impossible d'évaluer cpivot pour le moment
            for t in range(pivot):
                candidats[t], curseurs[t] = seek_to_document(postings_list[t], curseurs[t], doc_pivot) # Déplacer le pointeur au document cpivot ou suivant

return Ans

```

Algorithmme WAND

```
def all_queries(file, postings_clipping=False, list_splitting=False):
    queries = read_queries()
    with open(file, 'r') as f:
        print("load index")
        index = json.load(f)

    for k in [10, 1000]:
        print("--- k =", k)
        start_time = time.time()
        cpt = 0
        for query in queries:
            cpt += 1
            print(cpt)
            if postings_clipping:
                WAND(query, index, k, postings_clipping = True)
            else:
                if list_splitting:
                    WAND(query, index, k, list_splitting = True)
                else:
                    WAND(query, index, k)
        end_time = time.time()
        total_time = end_time - start_time
        avg_time = total_time / len(queries)
        print("----- Le temps moyen par requête est de : ", avg_time)
```

```
def read_queries():
    """
    Permet de lire les 6988 dev queries
    """
    list_queries = []
    with open('queries/msmarco-passage/queries.dev.small.tsv', 'r', encoding='utf-8') as file:
        reader = csv.reader(file, delimiter='\t')
        for row in reader:
            query_text = row[1]
            query_tokens = query_text.split()
            list_queries.append(query_tokens)
    #indices = [5238, 2, 204, 1, 6227]
    #return [list_queries[i] for i in indices]
    return list_queries[1:50]
```

```
if __name__ == '__main__':
    print("==== DeepImpact ====")

    print("Index inversé sans traitement : ")
    all_queries("indexes/inverted_index_deepimpact.json")

    print("Postings : ")
    all_queries("indexes/index_postings_deepimpact.json", postings_clipping=True)

    print("List splitting : ")
    all_queries("indexes/index_splitting_deepimpact.json", list_splitting=True)

    print("\n==== BM25 ====")

    print("Index inversé sans traitement : ")
    all_queries("indexes/inverted_index_bm25.json")

    print("Postings : ")
    all_queries("indexes/index_postings_bm25.json", postings_clipping=True)

    print("List splitting : ")
    all_queries("indexes/index_splitting_bm25.json", list_splitting=True)
```

Tests WAND


```

1 # maxscore.py -> @ maxscore
2 import heapq
3 import json
4 import csv
5 import time
6
7 def seekgeq(postings_list, d):
8     """
9     Fonction pour chercher et retourner la position dans une liste de postings
10    où le document est supérieur ou égal à la valeur donnée 'd'.
11    """
12    position = 0
13    while position < len(postings_list) and postings_list[position][0] < d:
14        position += 1
15    return position
16
17 def argmax(liste):
18     """
19     Fonction pour récupérer l'argmax (numpy ne fonctionne pas en ssh...)
20     """
21    max_val = float('-inf')
22    max_idx = -1
23
24    for i in range(len(liste)):
25        if liste[i][0] > max_val:
26            max_val = liste[i][0]
27            max_idx = liste[i][1]
28
29    return max_idx
30
31 def maxscore(postings_lists, Ut, k, list_splitting=False, dico_corresp=None):
32     """
33     Algorithme MaxScore pour trouver les k meilleurs documents à partir des listes de postings
34     en utilisant les valeurs Ut précalculées pour chaque terme.
35     """
36    c = len(postings_lists) # nombre de termes dans la liste des postings
37    active = set(range(c)) # termes actifs
38    passive = set() # termes passifs
39    sum_pass = 0 # somme des valeurs Ut des termes passifs
40    heap = [] # tas des meilleurs documents trouvés jusqu'à présent
41    c = [0] * c # curseurs pour chaque terme
42    theta = float('-inf') # seuil du tas des meilleurs documents
43
44    cpt=0
45    while active and cpt<1000000:
46        # Sélectionner le prochain document en cherchant la valeur minimale parmi les curseurs des termes actifs
47        min_postings = [(postings_lists[t][c[t]]][0], t) for t in active if c[t] < len(postings_lists[t])]
48        if not min_postings:
49            break
50        d = min(min_postings)[0]
51        # Mettre à jour les curseurs pour les termes passifs
52        for t in passive:
53            c[t] = seekgeq(postings_lists[t], d)
54
55        # Calculer le score du document en additionnant les impacts scores des postings correspondants
56        score = sum(postings_lists[t][c[t]][1] for t in active if c[t] < len(postings_lists[t]) and postings_lists[t][c[t]][0] == d)
57
58        # Mettre à jour les curseurs pour les termes actifs
59        for t in active:
60            if c[t] < len(postings_lists[t]) and postings_lists[t][c[t]][0] == d:
61                c[t] += 1
62
63        # Vérifier le score par rapport au tas des meilleurs documents et mettre à jour si nécessaire
64        if score > theta:
65            heapq.heappush(heap, (score, d))
66            if len(heap) > k:
67                heapq.heappop(heap)
68            theta = heap[0][0]
69
70        # Expansion de l'ensemble passif si nécessaire
71        if cpt%1000==0:
72            lg_postings = [(len(postings_lists[t]),t) for t in active]
73            if lg_postings:
74                y = argmax(lg_postings)
75                if sum_pass + Ut[y] < theta:
76                    active.remove(y)
77                    passive.add(y)
78                    if list_splitting==True and dico_corresp.get(y)!=None:
79                        sum_pass += (Ut[y] - dico_corresp.get(y))
80                    else:
81                        sum_pass += Ut[y]
82
83    cpt+=1
84
85    return heapq.nlargest(k, heap)

```

MaxScore

```

1 def one_query_list(query, postings, k):
2     postings_query = []
3     liste_Ut = []
4     dico = {} # dico correspondre à l'indice de M avec le score U_L(t)
5     for term in query:
6         if term in postings:
7             if postings[term].get('L')!=None:
8                 postings_query.append(sorted(postings[term]['L']["postings"], key=lambda x: x[1], reverse=False))
9                 liste_Ut.append(postings[term]['L']["Ut"])
10            if postings[term].get('H')!=None:
11                postings_query.append(sorted(postings[term]['H']["postings"], key=lambda x: x[1], reverse=False))
12                liste_Ut.append(postings[term]['H']["Ut"])
13            dico[len(postings_query)-1] = postings[term]['L']["Ut"]
14    maxscore(postings_query, liste_Ut, k, list_splitting=True, dico_corresp=dico)
15
16 def all_queries(file, postings_clipping=False, list_splitting=False):
17     queries = read_queries()
18     with open(file, 'r') as f:
19         print("load index")
20         postings = json.load(f)
21
22     for k in [10,1000]:
23         print("--- k = ",k)
24         start_time = time.time()
25         for query in queries:
26             if postings_clipping:
27                 one_query_postings(query, postings, k)
28             else:
29                 if list_splitting:
30                     one_query_list(query, postings, k)
31                 else:
32                     one_query(query, postings, k)
33         end_time = time.time()
34         total_time = end_time - start_time
35         avg_time = total_time / len(queries)
36         print("----- Le temps moyen par requête est de : ", avg_time)
37
38 def read_queries():
39     """
40     Permet de lire les 6000 dev queries
41     """
42     list_queries = []
43     with open('queries/renarco-passage/queries.dev.small.tsv', 'r', encoding='utf-8') as file:
44         reader = csv.reader(file, delimiter='\t')
45         for row in reader:
46             query_text = row[1]
47             query_tokens = query_text.split()
48             list_queries.append(query_tokens)
49     #indices = [5130, 2, 204, 377, 223]
50     #return [list_queries[i] for i in indices]
51     return list_queries[:100]
52
53 if __name__ == '__main__':
54
55     print("\n===== BM25 =====")
56     print("Index inversé sans traitement : ")
57     all_queries("indexes/inverted_index_bm25.json")
58
59     print("Postings : ")
60     all_queries("indexes/index_postings_bm25.json", postings_clipping=True)
61
62     print("List splitting : ")
63     all_queries("indexes/index_splitting_bm25.json", list_splitting=True)
64
65     print("===== DeepImpact =====")
66     print("Index inversé sans traitement : ")
67     all_queries("indexes/inverted_index_deepimpact.json")
68
69     print("Postings : ")
70     all_queries("indexes/index_postings_deepimpact.json", postings_clipping=True)
71
72     print("List splitting : ")
73     all_queries("indexes/index_splitting_deepimpact.json", list_splitting=True)

```